


Arquitetura de Dados: Behavior Score na Oracle Cloud (OCI)

1. Visão Geral da Solução

A arquitetura proposta foi desenhada na Oracle Cloud Infrastructure (OCI) seguindo as melhores práticas de **Cloud Native** e o pilar de **Otimização de Custos (FinOps)**. O projeto adota uma abordagem **100% Serverless** orientada a eventos, combinada com o padrão **Lakehouse (Medalhão)**. Isso garante escalabilidade horizontal transparente, segurança "by design" e um modelo de cobrança estritamente *pay-as-you-go* (pague pelo uso).



2. Detalhamento da Arquitetura por Camada

A. Ingestão Segura e Serverless (Ingestion Layer)

- **Serviços OCI:** Events, Functions, Vault.

- **Como Funciona:** O pipeline é totalmente automatizado. O **OCI Events** atua como gatilho (cron) que invoca o **OCI Functions**. Para garantir conformidade de segurança e eliminar credenciais *hardcoded*, a função utiliza *Resource Principals* para buscar a chave do Google Drive criptografada no **OCI Vault**. Em seguida, realiza a carga incremental dos dados, depositando-os no Data Lake.

B. Data Lake e Processamento (Storage & Processing Layer)

- **Serviços OCI:** Object Storage, Data Flow.
- **Como Funciona:** Os dados fluem por três estágios lógicos no **OCI Object Storage**:
 - **Bronze (Raw):** Dados brutos ingeridos (~5.33 GiB).
 - **Silver (Cleaned):** Dados higienizados e convertidos para Parquet (~5.14 GiB fragmentados em 943 objetos).
 - **Gold (Feature Store):** Dados agregados prontos para consumo (~1.72 GiB).
- **O Motor de ETL:** A transformação entre as camadas é feita pelo **OCI Data Flow** (Apache Spark 100% gerenciado). Ele processa a volumetria de forma distribuída e desliga a infraestrutura imediatamente após a conclusão.

C. Governança e Segurança (Data Catalog & IAM)

- **Serviços OCI:** Data Catalog, IAM.
- **Como Funciona:** O **OCI Data Catalog** realiza o *Harvesting* automático, inferindo os esquemas do Object Storage para garantir que os dados sejam descobríveis. O **OCI IAM** aplica políticas de acesso granular (RBAC), garantindo que apenas os serviços autorizados e os cientistas acessem a Feature Store.

D. Consumo e Machine Learning (Consumption Layer)

- **Serviços OCI:** MySQL HeatWave, Data Science.
- **Como Funciona:** O **MySQL HeatWave** permite consultas SQL analíticas de alta performance diretamente no Object Storage. Em paralelo, o **OCI Data Science** consome a camada Gold para o treinamento e inferência do modelo de Machine Learning (Behavior Score).

E. Observabilidade Proativa (Observability & Monitoring)

- **Serviços OCI:** Logging, Monitoring, Notifications.
- **Como Funciona:** Toda a telemetria do Functions e do Data Flow é enviada para a central de observabilidade. O **OCI Logging** retém os rastreios de execução, enquanto o **OCI Monitoring** avalia o *health* da esteira. Qualquer falha nos jobs aciona o **OCI Notifications**, que alerta a engenharia proativamente.

3. Estratégia de Infraestrutura e FinOps

Uma arquitetura madura não é apenas funcional, mas financeiramente otimizada.

Otimização do OCI Data Flow (Apache Spark)

- **Cenário Inicial:** O job `Job_Bronze_to_Silver` utilizava uma máquina `VM.Standard.E4.Flex` com 4 OCPUs e 32 GB de RAM.
- **Ajuste FinOps:** Para processar a volumetria mensal de ~12.2 GiB, essa máquina estava superdimensionada. Reduzimos o *Shape* na estimativa final para:
 - **Driver:** 2 OCPUs e 16 GB de RAM.
 - **Executors:** 2 instâncias de 1 OCPU e 8 GB de RAM cada.
 - *Justificativa:* Essa configuração lida com o volume atual com extrema folga, mitigando o problema de *Small Files* (visto na camada Silver) e derrubando o custo computacional do ETL para centavos de dólar.

Dimensionamento do OCI Data Science

- **Cenário:** Equipe de 3 Cientistas de Dados trabalhando em horário comercial (176 horas mensais cada).
- **Ajuste FinOps:** Configuramos **3 instâncias separadas** (para evitar concorrência de kernel e garantir governança individual) operando por 176 horas úteis. O serviço conta com *Auto-Deactivation* para desligar as instâncias ociosas (ex: finais de semana), garantindo que pagaremos apenas por 528 horas totais no mês, e não pelas horas ociosas.

4. Total Cost of Ownership (TCO) Mensal Estimado

A tabela abaixo detalha a estimativa de custos para o processamento de toda a rotina mensal (com base na calculadora oficial da OCI).

Camada	Serviço OCI	Consumo Mensal Configurado	Custo Estimado (USD)
Ingestão	OCI Functions	1 invocação diária (300.000 ms)	\$ 0,00
Armazenamento	OCI Object Storage	13 GB de armazenamento no Lake	\$ 0,08

Processamento	OCI Data Flow	2 execuções mensais (Shapes otimizados)	\$ 0,37
Governança	OCI Vault / Catalog	Chamadas de API padrão	\$ 0,00
Data Science (Compute)	Virtual Machine (E4.Flex)	3 instâncias x 176 horas/mês (528h)	\$ 39,07
Data Science (Storage)	Block Volume	300 GB de disco provisionado	\$ 9,05
TOTAL ESTIMADO			~ \$ 48,57 / mês

Conclusão de Negócio: *"Nossa arquitetura prova matematicamente o valor do modelo Serverless na nuvem Oracle. Toda a nossa esteira de Ingestão, Armazenamento e ETL do Lakehouse tem custo quase nulo (~\$ 0,45/mês). O investimento de ~US\$ 48 foca exclusivamente no que gera valor para o negócio: a infraestrutura computacional para nossos cientistas de dados treinarem o Behavior Score."*