

Relatório do Estudo de Público-Alvo

1. Sumário

Este estudo processou uma volumetria de **3.900.378 registros** provenientes das bases de dados da Claro. A Tabela Cadastral foi enriquecida através do *join* com as variáveis **SCORE_01** e **SCORE_02** (*base_score_bureau_movel*), permitindo a análise do perfil de risco dos CPFs perante os Bureaus de Crédito. Complementarmente, a tabela de pagamentos foi utilizada como referência para identificar a posse de planos Pós-Pagos no ato da contratação do plano Controle. O processo de construção da tabela respeitou a temporalidade para não contaminar a análise com dados futuros.

2. Objetivos

O propósito central deste estudo é diagnosticar o perfil dos clientes na transição para o plano Controle e mensurar o impacto dessa migração no FPD (*First Payment Default*). A análise busca responder a perguntas de negócio, estruturadas nos seguintes pilares:

Análise de Desempenho e Mercado:

- Taxa Global de Inadimplência: Qual a proporção real de FPD na base atual?
- Conversão e Adesão: Qual o volume de aderência do plano Controle?
- Comportamento de Safra (*Vintage*): Como o FPD evolui ao longo dos meses de contratação?

Perfil e Comportamento do Cliente:

- Demografia e Ciclo de Vida: Como a idade influencia a propensão ao pagamento?
- Ecossistema de Produtos: Qual o impacto do tipo de produto na fidelidade do cliente?
- Situação Sócio-Fiscal: De que forma a classificação fiscal perante a receita federal e profissional impacta o risco de crédito?

Validação de Ferramentas de Risco:

- Eficiência de Bureau: Qual o poder discriminatório dos Scores 01 e 02 na identificação de "maus" pagadores?

Hipóteses de Negócio (Testes de Significância): Para fundamentar a estratégia de *Feature Engineering*, este estudo submete a teste as seguintes premissas:

- **H1:** Clientes beneficiários de programas sociais apresentam maior sensibilidade à inadimplência.
- **H2:** Perfis com maior estabilidade ou maior poder aquisitivo (Empresários e Funcionários Públicos) apresentam menor taxa de FPD.

- **H3:** O relacionamento prévio com planos Pós-pago é um indicador de menor risco de inadimplência.

3. Metodologia

A execução deste estudo dividiu-se em duas frentes principais: Engenharia de Dados e Análise Analítica/Estatística.

Engenharia de Dados

Utilizou-se o **Google Colab** integrado ao **PySpark** para a manipulação da volumetria de ~4 milhões de registros, aproveitando o processamento distribuído para garantir performance nos *joins* complexos entre as tabelas Cadastral, Bureau e Pagamento.

Ambiente Analítico:

- **Exploração de Dados (EDA):** A análise foi conduzida em ambiente **Jupyter Notebook**, utilizando a biblioteca **Pandas** para manipulação dos dados
- **Visualização:** A biblioteca **Matplotlib** foi utilizada para a estruturação base dos gráficos, enquanto o **Seaborn** foi empregado para visualizações estatísticas avançadas e matrizes de correlação.
- **Testes de Hipótese:** Foi utilizado a biblioteca **statsmodels**, e para todos foram feitas 10.000 simulações ,com reposição, de tamanho 250.

3.1 Notebooks

[Criação da Tabela](#)

[Análise](#)

4. Análise Exploratória de Dados


4.1 Análise de Desempenho e Mercado

4.1.2 Adesão

O conjunto de dados analisado, tendo a Tabela Cadastral como principal por possuir a maior quantidade de registros, compreende um universo de 3.590.459 CPFs únicos. No total, foram 3.900.378 consultas de adesão ao plano Controle, apresentando a seguinte distribuição de conversão:

- **Conversão (Contratados):** 2.696.621 registros, representando uma taxa de adesão de 69,1%. Este subconjunto constitui a base para a modelagem do FPD, onde o comportamento de pagamento pós-adesão é observado.
- **Não Convertidos:** 1.203.757 registros (30,9%). Este volume engloba dois perfis distintos:
 1. Reprovação por Risco: Clientes que não atingiram os critérios mínimos das políticas de crédito vigentes.
 2. Desistência: Clientes que, embora elegíveis, optaram pela desistência da contratação.

Análise de Adesão: Total de 3.900.378 Registros




4.1.2 Inadimplência

Dentro do universo de **2.696.621 contratações** efetivadas, identificou-se que **574.380 (21,3%) clientes** entraram em regime de **FPD (First Payment Default)** ou seja não pagaram a primeira fatura. Isso resulta em uma taxa de inadimplência inicial de **21,3%**.

- **Definição do Target:** Para fins de modelagem, o **FPD** constitui o target da previsão do algoritmo na identificação dos perfis insolventes.

Proporção de Inadimplência (FPD)



4.1.3 Grupo controle

Para garantir uma validação estatística isenta de interferências das políticas de crédito atuais, a base de contratações foi segmentada em dois braços:

- **Público Geral (Aprovados por Política):** Composto por 2.583.341 registros (95,8%). Este grupo reflete os clientes que superaram os filtros de crédito vigentes da Claro.
- **Grupo Controle (Aprovação Automática):** Composto por 113.280 registros (4,2%), identificados pelos 6º e 7º dígitos do CPF (ZZ ou ZX). Por regra de negócio, estes clientes são aprovados automaticamente (exceto em casos de óbito ou menoridade), independentemente do seu Score de Bureau.


A análise comparativa das taxas de inadimplência entre os grupos revela o impacto direto da seleção de risco:

- **Taxa de FPD (Público Geral):** 20,9%
- **Taxa de FPD (Grupo Controle):** 30,8%


A diferença de 9,9 pontos percentuais entre as taxas evidencia o "risco puro" da população sem filtros. O Grupo Controle atua como o padrão-ouro de validação, permitindo medir a força real das variáveis de Bureau e de perfil sem que o modelo "aprenda" apenas o que as regras atuais já aprovaram.

Esta disparidade, validada pelo teste de hipótese, confirma que as políticas de crédito vigentes são eficazes ao mitigar cerca de **9,9 pontos percentuais** de inadimplência latente. No entanto, o hiato de risco entre os grupos delimita a **janela de oportunidade** para o novo modelo: a capacidade de identificar, de forma granular, subgrupos com potencial de inadimplência dentro da massa hoje classificada como 'alto risco'. Esse refinamento permitirá expandir a base de contratações.

Distribuição de FPD por Grupo (Controle vs. Geral)



Validação de Eficácia: Política de Crédito Atual vs. Aleatoriedade




4.1.4 Safras

A base de dados compreende o histórico de **6 safras mensais**, abrangendo o período de **outubro de 2024 a março de 2025**. A distribuição temporal apresenta uma estabilidade, com um volume médio de **449 mil clientes por mês** e uma taxa de **FPD em torno de 21%**.

Para garantir a robustez estatística e a capacidade de generalização do modelo, deve ser adotado a seguinte estratégia de particionamento:

- **Base de Desenvolvimento (Treino):** Compreende as safras de **outubro/24 a janeiro/25**, totalizando **1.822.251 clientes**. Este subconjunto apresenta um FPD de **21,2%** e será utilizado para o aprendizado de padrões e ajuste dos hiperparâmetros do algoritmo.
- **Base de Validação Temporal (Out-of-Time - OOT):** Composta pelas safras de **fevereiro/25 e março/25**, com **874.370 clientes** e FPD de **21,3%**.

A utilização de um **OOT** é uma prática mandatória em modelagem de risco de crédito. Ela permite avaliar se o modelo mantém sua performance (KS e AUC) em meses subsequentes aos de treinamento, simulando a aplicação real do modelo em produção validando que eventuais sazonalidades não invalidam as predições.



4.2 Perfil e Comportamento do Cliente

4.2.1 Idades

A análise da estrutura etária revelou que a idade é fator relevante no comportamento de contratação e inadimplência.

Distribuição Etária e Conversão:



- **Contratados:** Apresentam uma mediana de idade de **42 anos**, indicando um público mais maduro e, teoricamente, com maior estabilidade financeira.
- **Não Contratados:** A mediana cai para **36 anos**, sugerindo que o público mais jovem encontra mais barreiras (seja por política de crédito ou por desinteresse no produto).

A Correlação entre Idade e FPD: Observa-se uma **correlação inversa** entre a faixa etária e a inadimplência inicial. O risco decresce à medida que a idade avança:


- **Público Jovem (até 25 anos):** Apresenta a maior taxa de FPD, com **26,0%**.
- **Público Sênior (60 anos ou mais):** Apresenta o menor risco da base, com apenas **17,2%**.

O Sinalizador de Risco dos Dados Ausentes (*Missing Values*): A análise identificou **6.101 registros** sem a informação de idade. Embora representem uma parcela pequena da base, este grupo concentra a **maior taxa de inadimplência observada: 34,7%**.

Este padrão indica que a ausência de dados cadastrais não é aleatória (*Not Missing At Random - NMAR*), mas sim um **indicador de risco**, ou seja, ausência que possui informação. Devido a sua alta correlação com o FPD, é importante que essa informação seja tratada com uma variável preditora.



Taxa de Inadimplência (FPD) por Faixa Etária



4.2.2 Portfólio

A base de dados apresenta a segmentação dos clientes em três categorias de produtos: **CMV, NET e DTH**. Embora a natureza da posse (aquisição de combo ou produto preexistente) não tenha sido detalhada na documentação técnica, a análise de volumetria e risco revela comportamentos distintos:


Distribuição e Estabilidade:

- **CMV (Core):** É o produto predominante, concentrando **2.633.900 registros**. Sua taxa de FPD de **21,23%** está dentro da média global da companhia.
- **NET:** Com **56.080 registros**, apresenta um comportamento de risco similar ao CMV (**21,3%**), sugerindo que este público compartilha o mesmo perfil socioeconômico de risco.

O Ponto de Atenção (Outlier de Risco):

- **DTH:** Representa uma pequena fração do portfólio (**6.641 registros**), porém com uma performance de crédito severamente degradada. A taxa de FPD deste grupo é de **37,51%**, um incremento de risco de quase **16 pontos percentuais** em relação à média global.

Implicação para o Modelo: Apesar da baixa volumetria do grupo DTH, sua taxa de inadimplência discrepante indica que o produto em si (ou o canal de venda associado a ele) é um **preditor de altíssimo risco**.



4.2.3 Status Perante a Receita Federal

Como esperado, a maior parte dos clientes possui status Regular sendo 2.669.344 com taxa de FPD de 21.3%. Seguido de Pendente de Regularização com 21.261 clientes e taxa de FPD de 17.5%. A sem Status é a terceira maior com 5.264 cliente e FPD de 34.3%. A Suspensa possui 370 clientes e 33.8% de FPD, a cancelada possui apenas 8 cliente, ou seja um valor desprezível dentro da volumetria da base de dados, mas com 62.5% de FPD. Mas estranhamente a base possui 374 clientes com o status Titular Falecido, sendo que faz parte da regra de negócio não aceitar clientes com status falecido, e essa possui uma taxa de 46.5% de FPD

A análise da situação fiscal dos CPFs junto à Receita Federal do Brasil (RFB) revelou padrões de risco e, mais importante, **brechas na execução das regras de negócio** atuais.


Distribuição de Risco por Status Fiscal:

- **Regular (Core):** Como esperado, concentra a vasta maioria da base com **2.669.344 registros**. Sua taxa de FPD de **21,3%** serve como o referencial de normalidade da carteira.
- **Pendente de Regularização:** Surpreendentemente, este grupo (**21.261 clientes**) apresenta um risco menor que a média global, com **17,5% de FPD**. Isso pode indicar um perfil de cliente que possui pendências burocráticas, mas mantém um comportamento de pagamento resiliente.
- **Sem Status e Suspensa:** Estes grupos somam cerca de **5.600 registros** e apresentam um salto crítico de risco, com FPDs entre **33,8% e 34,3%**, podem ser indicativos de fraude.

Identificação de Anomalias é Possível Fraude: O ponto de maior atenção reside nos status que deveriam ter sido bloqueados pelo sistema de vendas, mas que foram efetivados:

- **Titular Falecido:** Foram identificados **374 registros** ativos nesta condição. Além de representar um descumprimento de regra de negócio, este grupo apresenta um FPD alarmante de **46,5%**.
- **Cancelada:** Com apenas 8 registros, apresenta o risco máximo da base (**62,5%**).

Insight de Engenharia e Risco: A presença de CPFs de "Titulares Falecidos" com quase 50% de inadimplência é um forte indício de **Fraude de Identidade (Terceiros)**, bem como a presença de Status **Sem Status e Suspensa**. Para o modelo de Ciência de Dados, esses status devem receber um peso de penalização.






4.3 Validação de Ferramentas de Risco

4.3.1. Análise de Performance dos Bureaus: SCORE_01 vs. SCORE_02

A base analítica contempla dois scores provenientes de Bureaus de Crédito distintos (SCORE_01 e SCORE_02), ambos apresentando poder discriminatório satisfatório. Contudo, ao isolarmos a performance tanto na população geral quanto no Grupo Controle (por ser um público sem viés de seleção), o SCORE_02 destaca-se com desempenho superior em todas as dimensões avaliadas:


- **Poder de Discriminação (KS - Grupo Controle):** O SCORE_02 alcançou um KS de 38,1%, superando significativamente os 33,6% do SCORE_01. Esse resultado mostra uma maior eficiência na separação entre adimplentes e inadimplentes em um cenário de aprovação cega.
- **Rank-Ordering e Monotonicidade (Universo de Contratantes):** O SCORE_02 apresenta uma curva de risco mais acentuada e consistente. Nas faixas de maior risco (decis iniciais), ele isola um FPD de 47,1%, mostrando-se mais eficaz que o SCORE_01, que captura apenas 38,8% no mesmo intervalo.
- **Aderência Estatística:** A correlação negativa com o FPD é nitidamente mais robusta no SCORE_02 (-0,22) em comparação ao SCORE_01 (-0,12), consolidando-o como a *feature* preditiva primária para o treinamento do modelo.

Embora ambos os indicadores agreguem valor à análise, o SCORE_02 possui uma sensibilidade superior para identificar perfis de altíssimo risco. A utilização desse score permite a implementação de políticas de corte mais precisas, otimizando a rentabilidade da carteira ao reduzir perdas severas nas faixas de entrada.




Análise de Scores: Volume vs. Risco (Sem Grupo Controle)


Performance: SCORE_01



Performance: SCORE_02



4.4 Análise do Perfil Socioeconômico



4.4.1 Hipóteses de Negócio (Testes de Significância)


Para fundamentar a inclusão de variáveis demográficas no modelo preditivo, realizamos testes de hipóteses utilizando 10.000 simulações com reposição de amostras tamanho 250 . O objetivo foi validar se as disparidades de risco observadas são consistentes ou fruto de flutuações aleatórias da base.

H1: Impacto de Benefícios Sociais na Inadimplência

A análise confirmou que clientes beneficiários de programas sociais (Auxílio Emergencial/Bolsa Família) apresentam uma vulnerabilidade financeira significativamente maior:

- **Resultados:** A taxa de FPD deste grupo é de **25,6%**, contra **18,0%** dos demais clientes.
- **Conclusão Estatística:** Com um **P-valor de 0,00000** e a completa separação das distribuições na simulação, rejeitamos a hipótese nula (H0). A diferença de **7,6 p.p.** não é aleatória, confirmando que a dependência de auxílios é um preditor de risco.

H1: Clientes com Benefícios Sociais têm MAIOR FPD




H2: Estabilidade Profissional e Poder Aquisitivo

Testamos se perfis com maior estabilidade financeira (Empresários, Diretores e Funcionários Públicos) possuem um comportamento de pagamento superior:

- **Resultados:** Este segmento apresentou um FPD médio de **15,7%**, enquanto o restante da base registrou **22,1%**.
- **Conclusão Estatística:** A simulação demonstrou que as curvas de densidade são distintas e distantes do limiar de significância de 5%. Aceitamos a hipótese de que a estabilidade profissional atua como um fator atenuante de risco, reduzindo a inadimplência em **6,4 p.p.** em relação à média do público geral.

H2: Empresários e Func. Públicos têm MENOR FPD




H3: Fidelidade e Relacionamento Prévio (Pós-pago)

Investigamos se o fato de o cliente já possuir um plano Pós-pago no ato da contratação do Controle indica um perfil de risco menor:

- **Resultados:** Clientes com histórico Pós-Pago apresentam um FPD de **16,1%**, contra **23,5%** dos demais.
- **Conclusão Estatística:** O teste resultou em significância máxima ($p < 0,05$). O relacionamento prévio com produtos de maior valor agregado é um indicador de menor tendência à inadimplência, validando a premissa de que a fidelidade à marca e o histórico de pagamento positivo são variáveis importantes para o score final.

H3: Clientes com plano Pós-Pago têm MENOR FPD



5. Conclusão e Recomendações Estratégicas

A análise dos ~4 milhões de registros permitiu mapear o perfil de risco da base e validar algumas variáveis com poder discriminatório para a predição do **FPD (Inadimplência de Primeira Fatura)**. O estudo analisou que, embora o Score de Bureau seja um excelente balizador, a inclusão de variáveis comportamentais e demográficas pode permitir à Claro atingir níveis mais satisfatórios de assertividade.

Principais Variáveis e Padrões Identificados:

- **Poder Discriminatório Superior (SCORE_02):** O SCORE_02 consolidou-se como o indicador externo mais robusto, apresentando um **KS de 38,1%** e um **AUC de 0,750** [cite: 2026-02-09]. Sua capacidade de isolar o risco nos decis iniciais (47,1% de FPD) o torna a *feature* espinhal do futuro modelo.
- **Vulnerabilidade e Benefícios Sociais (H1):** Confirmou-se um padrão de risco elevado (**25,6% FPD**) para clientes dependentes de auxílios governamentais. A separação total das curvas na simulação de Monte Carlo prova que este sinal é estatisticamente estável e deve ser usado para ajustes de limite de crédito.
- **Estabilidade e Fidelidade (H2 e H3):** Funcionários públicos, empresários e detentores de planos **Pós-pago** formam o estrato de maior segurança da carteira, com taxas de FPD até **6,4 p.p.** menores que a média global.
- **A "Escada" Etária:** Confirmamos que o risco é inversamente proporcional à idade, com jovens de até 25 anos apresentando **26% de FPD**, enquanto o público 60+ cai para **17,2%**.
- **Poder do Dado Ausente:** A ausência de informação de idade (*Missing Values*) é um preditor crítico, concentrando **34,7% de inadimplência**. Isso prova que o "vazio" na base não é aleatório, mas um indicador de risco latente.

Implicações para o Modelo e para o Negócio:

Os padrões identificados indicam que o modelo de **Ciência de Dados** não deve ser apenas reativo aos bureaus, mas sim proativo na identificação de perfis. A alta taxa de inadimplência em status de "Titular Falecido" (**46,5%**) evidencia uma oportunidade imediata de ganho financeiro através do saneamento de regras de engenharia no momento da venda.

Próximos Passos:

1. **Modelagem Final:** Integração das *features* validadas (Scores, Deltas de Bureau, Flags de Benefícios e Idade) em um algoritmo de *Gradient Boosting* (XGBoost/LightGBM).
2. **Estratégia Champion vs. Challenger:** Implementação teste controlado para validar o ganho de KS do novo modelo em relação à política atual, visando a redução seletiva do FPD sem comprometer o volume de vendas ou aumentar o volume de vendas sem aumentar o FPD, ou melhor ainda aumentar o volume de vendas reduzindo o FPD.

Esta base analítica, tem o propósito de contribuir para que o projeto esteja pronto para evoluir da fase de diagnóstico para a **implantação de uma inteligência de crédito** capaz de otimizar a rentabilidade e a segurança da migração para o plano Controle.