

Relatório de Engenharia de Dados: Camada Bronze para Silver

1. Infraestrutura e Ferramentas (OCI)

A arquitetura foi desenhada na Oracle Cloud Infrastructure (OCI) para suportar o processamento massivo de dados (Big Data), garantindo segurança e performance.

- **Processamento:** Utilização de Notebook Sessions no serviço OCI Data Science, configurado com uma instância VM.Standard.E5.Flex (32GB de RAM). com custo estimado de ~\$ 0.154 / hora
- **Motor de Dados:** Apache Spark (PySpark) otimizado com memória de driver de 20GB para lidar com volumes superiores a 100 milhões de registros.
- **Armazenamento:** OCI Object Storage organizado em camadas (*Buckets*), utilizando o formato Parquet com compressão Snappy para redução de custos e ganho de performance em leitura.
- **Rede e Segurança:** Implementação de VCN (Virtual Cloud Network) com Service Gateway, permitindo tráfego privado entre o Spark e o Storage. Autenticação via Resource Principals (Dynamic Groups), eliminando o uso de chaves manuais.

2. Estratégia de Saneamento e Qualidade

Para padronizar a base e garantir a integridade dos modelos de Machine Learning, foi adotada uma política de Valores Sentinela para preenchimento de campos nulos, utilizando como base regras já adotadas pela claro:

- **-1:** Não se aplica. (Claro)
- **-2:** Não determinado. (Claro)
- **-3:** Não informado. (Caro)
- **-4:** Desconhecido (Criado nova categoria, para valores de natureza desconhecida).
- **-999:** Valor sentinela para erros ou outliers.
- **Datas:** Uso de **1900-01-01**, **1000-01-01** ou **9999-12-31**.

A transição da camada **Bronze** para a **Silver** realizou conversão de arquivos brutos (CSV/Parquet original) para um formato otimizado de leitura:

- **Formato de Destino: Parquet** com compressão Snappy (melhor relação entre tamanho de disco e velocidade de leitura).
- **Otimização de Memória:** Configuração do Spark Driver para **20GB de Heap Space** para suportar o processamento de 100M+ registros sem erros de estouro de memória (*Out of Memory*).

- **Particionamento Estratégico:** Os dados foram salvos utilizando `partitionBy` em colunas temporais (SAFRA, ANO_INSERTAO, MES_INSERTAO), permitindo a "Poda de Partição" (*Partition Pruning*) e acelerando consultas futuras.
- **3. Resumo das Bases Processadas**
- **Tabela cadastral:** Contém as informações cadastrais dos clientes. As variáveis foram desanonimizadas e o dicionário de dados está na tabela: [Dicionario Tabela cadastral](#)
- **Full Score Bureau:** Consolidação de scores de crédito externos contratados.
- **Telco:** Variáveis de comportamento e consumo de telecomunicações (anonimizadas).
- **Recarga:** Tabela fato de recargas pré-pagas (100M+ linhas), possuindo mais 11 dimensões em CSV.
- **Pagamento:** Histórico financeiro de clientes com planos controle e pós-pagos.

5. Próximos Passos (Silver → Gold)

Com as bases cadastral, telco, recarga +DIMS, pagamento e score devidamente limpas e padronizadas na camada Silver, iniciaremos:

1. **Feature Engineering:** Criação de variáveis agregadas (ex: média de recarga nos últimos 3 meses).
2. **Tabela Única (ABT):** Join das tabelas através do identificador único criado **NUM_CPF+SAFRA** para criação da *Analytical Base Table*.
3. **Treinamento de Modelo:** Início da modelagem preditiva de risco de crédito.