

Relatório: Construção do Book de Pagamentos (Feature Engineering)

1. Visão Geral e Arquitetura do Pipeline

O Book de Pagamentos foi desenvolvido para mapear o histórico de adimplência dos clientes, o esforço financeiro e o comportamento transacional dos clientes Pós Pago da operadora. Utilizando a arquitetura de **Spine Table (Tabela Espinha)** com a chave primária ID_UNICO (CPF + Safra), este pipeline traduz o histórico de faturamento em *features* preditivas de alto valor para o modelo de análise de risco de crédito (migração para o plano Controle e predição de *First Payment Default* - FPD).

A arquitetura garante que o motor de *Machine Learning* interprete corretamente a jornada de clientes que possuem múltiplos contratos ativos (DW_NUM_CLIENTE) simultaneamente ou ao longo do tempo.

1.1 Infraestrutura

- **Ambiente de Desenvolvimento:** Utilização do **OCI Data Science (Oracle Cloud Infrastructure)**.
- **Especificação de Hardware:** Instância **VM.Standard.E5.Flex** configurada com **3 OCPUs** e **32 GB de Memória RAM**. Essa escolha permitiu o processamento paralelo eficiente do PySpark e a manipulação de grandes volumes de dados em memória a um custo estimado de ~ \$0,154 / hora.
- [Base de dados na OCI](#)

2. Governança, Data Quality e Decisões Analíticas

Para transformar uma base de dados transacional complexa em um *dataset* analítico limpo, três pilares técnicos foram implementados:

- **Tratamento de Missing Not At Random (MNAR) e Sentinelas:** Identificou-se que 28.03% da base possuía ausência nas datas críticas de vencimento e pagamento, preenchidas com valores sentinelas de sistema (1900-01-01, 9999-12-31, -444444.0). Em vez de realizar um descarte enviesado (o que destruiria o poder preditivo do modelo), esses dados foram isolados na categoria SEM_STATUS. Isso permite que o algoritmo aprenda se a ausência de registro de sistema é, por si só, um indicativo de risco.
- **Agregação Multinível (Resolução de Cardinalidade de Contratos):** A contagem de faturas pagas (SEQ_FATURA) não foi feita por uma soma simples, o que geraria duplicidades irreais. O pipeline agrupa primeiro pelo contrato (DW_NUM_CLIENTE) para encontrar a fatura máxima de cada linha móvel, e apenas depois realiza a soma por CPF.

- **Zero Data Leakage:** Blindagem temporal estrita aplicando a regra `DAT_STATUS_FATURA < DATA_CORTE_SAFRA`, garantindo que eventos futuros de pagamento não vazem para a fotografia histórica do cliente.

3. Dicionário de Variáveis e Regras de Construção

As *features* geradas foram agrupadas em 4 domínios lógicos de risco de crédito:

A. Domínio: Maturidade e Estabilidade

Avalia o "tempo de casa" do cliente e sua distribuição geográfica.

Variável	Descrição / Regra de Construção	Relevância para o Modelo (FPD)
QTD_TOTAL_FATURAS_PAGAS	Soma da fatura mais alta (MAX_SEQ) de cada contrato vinculado ao CPF no período.	Uma das variáveis preditivas mais fortes. CPFs com histórico longo de faturas pagas apresentam risco de <i>default</i> substancialmente menor.
FLG_REGIONAL_{X}	Flags binárias (0 ou 1) indicando a presença do cliente nas 10 Unidades de Negócio (DW_UN_NEGOCIO).	Captura componentes de risco macroeconômico regionalizado (ex: impacto de desemprego focado em uma região).

B. Domínio: Comportamento de Adimplência (Atrasos)

O termômetro comportamental que cruza as datas de Vencimento e Criação do Pagamento.

Variável	Descrição / Regra de Construção	Relevância para o Modelo (FPD)

QTD_MAX_DIAS_ATRASO	O maior <i>Delta</i> em dias (DPD - <i>Days Past Due</i>) já registrado no histórico do cliente.	Indica o "pior cenário" de liquidez do cliente. Clientes com picos de atraso alto têm fluxo de caixa instável.
QTD_PERFIL_ATRASO_EM_DIA	Contagem de faturas pagas exatamente no dia do vencimento (Delta = 0).	Marcador forte de organização financeira.
QTD_PERFIL_ATRASO_ATRASADO	Contagem de faturas pagas após o vencimento (Delta > 0).	Indicador direto de estresse financeiro recorrente.
QTD_PERFIL_ATRASO_ADIANTADO	Contagem de faturas pagas antes do vencimento (Delta < 0).	Perfil de "Super Prime" (risco de crédito quase nulo).
QTD_PERFIL_ATRASO_SEM_STATUS	Contagem de faturas que caíram na regra de tratamento de sentinelas (MNAR).	Permite ao algoritmo isolar falhas operacionais sistêmicas do real risco do cliente.

C. Domínio: Sensibilidade Financeira e Custo do Crédito

Avalia como o cliente lida com juros e o volume monetário transacionado.

Variável	Descrição / Regra de Construção	Relevância para o Modelo (FPD)

VAL_TOTAL_PAG_FATURA	Soma total monetária de todas as faturas pagas historicamente.	Demonstra a capacidade real de pagamento (tamanho do bolso do cliente).
VAL_TOTAL_JUROS_PAGOS	Soma monetária exclusiva da rubrica VAL_JUROS_MULTAS_ITEM.	O custo extra suportado pelo cliente devido à sua ineficiência de pagamento.
QTD_FREQ_JUROS_{NIVEL}	Clusterização da frequência de pagamento de juros em 5 <i>bins</i> : Sem Juros (0), Insignificante (até 1.1), Moderado (até 5.0), Alto (até 50) e Muito Alto (> 50).	Resolve o problema da "cauda longa" da distribuição de juros (onde a média é R\$ 1.58, mas o máximo chega a R\$ 103k), linearizando a informação para o modelo de ML.

D. Domínio: Meios e Canais de Pagamento (Dummies Freqüenciais)

Mapeia a bancarização e a fricção no ato de pagar a conta.

Variável	Descrição / Regra de Construção	Relevância para o Modelo (FPD)

QTD_BANCO_{TRADICIONAL/FINTECH/NT1/OUTROS}	Mapeamento dos códigos de NUM_BANCO_PAGAMENTO em macro-categorias bancárias.	Perfis de clientes de bancos tradicionais possuem dinâmicas de inadimplência distintas de usuários exclusivos de <i>fintechs</i> .
QTD_FORMA_PAG_{ONLINE/DEBITO_DIRETO/...}	Tradução do código DW_FORMA_PAGAMENTO para métodos nominais.	Clientes em Débito Direto possuem atrito de pagamento zero, reduzindo drasticamente o <i>Churn</i> e o atraso involuntário.
QTD_STAT_FAT_{C/O}	Contagem do status do contrato (Fechado/Aberto).	Indica se o cliente costuma deixar resíduos em aberto na esteira de faturamento.

4. Relevância Estratégica para o Projeto

Enquanto o Book de Recarga mede a "fome de saldo" e o consumo do pré-pago, este **Book de Pagamentos** traz a disciplina financeira em planos Pós-Pago.

A grande inovação analítica desta etapa foi a recusa em apenas somar ou dropar dados problemáticos. O tratamento de **MNAR**, a clusterização manual da distribuição assimétrica de juros (evitando que *outliers* de R\$ 103.000,00 destruíssem os pesos do modelo) e a classificação da bancarização por *Fintechs* versus *Tradicionais* criam um mosaico comportamental frutífero.

Para a migração de planos Controle, onde o risco recai na esteira de *billing* (faturamento pós-uso), as *features* de DPD (*Days Past Due* / Atrasos) e custo recorrente de juros geradas por este código serão os pilares decisórios centrais para aprovação ou recusa da oferta de crédito.