

RELATÓRIO: CONSTRUÇÃO DA BASELINE

1. OBJETIVO

O objetivo central desta fase foi a estruturação de uma **Baseline** para prever o risco de *First Payment Default* (FPD). A metodologia adotada consistiu na construção incremental da base de dados, permitindo a verificação controlada do ganho de poder preditivo (KS) a cada novo bloco de informações incorporado ao modelo.

2. METODOLOGIA E GOVERNANÇA DE DADOS

Para garantir a integridade do modelo, foram aplicadas as seguintes diretrizes:

Corte Temporal Reversivo: Filtro para garantir que apenas eventos anteriores à data da SAFRA sejam considerados, evitando o vazamento de dados (*Data Leakage*).

- **Valores Sentinelas:**
 - **-4:** Identifica ausência de dado na base de origem (Bureau).
 - **-1:** Identifica ausência de dado após o cruzamento de bases (Não se aplica/Sem histórico).
- **FPD (Target):** Taxa de inadimplência no primeiro pagamento após a migração.

3. DICIONÁRIO DE VARIÁVEIS POR BLOCO

BLOCO I: Bureau de Crédito (score_01 e score_01_02)

Variável	Descrição
ID_UNICO	Chave primária (CPF + Safra).
GRUPO_CONTROLE	Flag binária para medição de impacto incremental.
SAFRA	Mês de referência do evento de crédito.
Flag_OOT	Indicador de validação fora do tempo (<i>Out-of-Time</i>).

FPD	Variável Target: {1: Inadimplente, 0: Adimplente}.
SCORE_01 / 02	Valores numéricos dos scores fornecidos pelo Bureau.
SCORE_01/02_MISSING	Flag binária (0/1) indicando ausência do dado original.

BLOCO II: Consumo e Perfil Telco

Variável	Descrição
CMV, NET, DTH	Indicadores de portfólio de produtos utilizados.
var_26 a var_93	Atributos numéricos de intensidade e frequência de consumo.
var_MISSING	Flag indicando que a informação não foi capturada na origem.
var_NAO_SE_APLICA	Flag de Left Join: identifica clientes sem histórico para o produto.

BLOCO III: Dados Cadastrais

Variável	Categoria	Descrição
IDADE	Demográfico	Idade cronológica na data da Safra.
FUNC_PUBL / PRIV	Ocupação	Identifica vínculo empregatício e status funcional.

var_07_MONETARIO	Renda	Atributo de alta magnitude relacionado ao poder de compra.
BOLSA_FAMILIA	Benefício	Identifica beneficiários de programas governamentais.
STATUSRF_...	Regularidade	Situação cadastral do CPF perante a Receita Federal.

BLOCO IV: Comportamento de Recarga

Variável	Descrição	Relevância
REC_TOTAL_VALOR_HIST	Soma de valores de recarga.	Indica Lifetime Value (LTV).
REC_DIAS_DESDE_ULTIMA	Recência da última recarga.	Preditores de risco (Inatividade = Risco).
QTD_SOS / TOTAL_SOS	Uso de crédito de emergência.	Sinaliza fragilidade financeira momentânea.
CONTROLE / POS_PAGO	Segmentação de plataforma.	Diferencia consumo zero por perfil de plano.

BLOCO V: Histórico de Pagamento

Variável	Descrição	Relevância
-----------------	------------------	-------------------

PAG_MAX_DIAS_ATRASO	Maior atraso histórico.	Preditor de inadimplência.
PAG_MEDIA_DIAS_ATRASO	Média aritmética de atrasos.	Diferencia atraso pontual
PAG_DESVIO_PADRAO	Volatilidade de atraso.	Avalia instabilidade de comportamento.
PAG_HISTORICO_MISSING	Flag de cliente sem histórico.	Segmento superior (25,38%).

4. ANÁLISE COMPARATIVA DE IMPACTO (KS INCREMENTAL)

<u>Dataframe</u>	<u>Shape (Linhas)</u>	<u>Variáveis</u>	<u>Proporção FPD</u>	<u>Perda Volumetria</u>
Baseline (Bureau)	2.633.900	13	21,23%	-
+ Telco	2.633.900	86	21,23%	0,00%
+ Cadastral	2.633.900	123	21,23%	0,00%
+ Recarga	1.891.934	135	22,40%	28,17% (Inner Join)
+ Pagamento	1.891.934	144	22,40%	0,00% (Left Join)

5. PRÓXIMOS PASSOS

A partir desta Baseline, as seguintes frentes de trabalho serão iniciadas:

1. **Reinclusão de Inativos:** Desenvolver tratamento para os 28% de clientes retirados no join de recarga, garantindo a cobertura total da base através de modelos específicos para "novos entrantes".
2. **Engenharia de Atributos Avançada:** Criação de variáveis de Clusterização e Segmentação para agrupar perfis não capturados pelas variáveis lineares.
3. **Enriquecimento Dimensional:** Cruzamento dos Books de Pagamento e Recarga com as tabelas de dimensão para extrair informações.
4. **Otimização do KS:** Teste de incremento de variáveis no modelo, avaliando se aumentam o poder preditivo.