

Construção do Book de Recargas (Feature Engineering)

1. Visão Geral e Arquitetura do Pipeline

O Book de Recargas foi desenvolvido para consolidar o histórico comportamental de mais de 100 milhões de eventos de inserção de crédito, agregando-os na visão do cliente ($ID_UNICO = NUM_CPF + SAFRA$). O objetivo primário é extrair sinais de estabilidade financeira, ritmo de consumo e risco de crédito para alimentar o modelo de predição de FPD (First Payment Default) na migração de planos Pré-pagos para Controle.

A arquitetura adotou o modelo de **Spine Table (Tabela Espinha)**, partindo da base cadastral de safras e realizando o enxerto (Join) do histórico transacional.

1.1 Infraestrutura

- **Ambiente de Desenvolvimento:** Utilização do **OCI Data Science (Oracle Cloud Infrastructure)**.
- **Especificação de Hardware:** Instância **VM.Standard.E5.Flex** configurada com **3 OCPUs** e **32 GB de Memória RAM**. Essa escolha permitiu o processamento paralelo eficiente do PySpark e a manipulação de grandes volumes de dados em memória a um custo estimado de ~ \$0,154 / hora.
- [Base de dados na OCI](#)

2. Governança, Data Quality e Data Lineage

Para garantir a robustez estatística e a confiabilidade do pipeline, três pilares de engenharia foram aplicados:

- **Zero Data Leakage (Filtro Anti-Vazamento):** Foi aplicada a regra estrita $DAT_INSERCAO_CREDITO < DATA_CORTE_SAFRA$. Nenhuma recarga feita no mês da safra ou em meses futuros contaminou a fotografia histórica do cliente. O modelo aprende apenas com o passado estrito.
- **Redução de Cardinalidade Segura:** Variáveis categóricas com centenas de domínios (ex: `COD_GRUPO_CARTAO`, `DSC_GRUPO_CARTAO_WPP`) foram tratadas. As categorias que representavam mais de 1% da base foram mantidas (One-Hot Encoding), e a "cauda longa" foi aglutinada na categoria OUTROS, evitando a explosão de dimensionalidade e o *Overfitting* das árvores de decisão.
- **Data Lineage (Rastreabilidade):** Padronização rigorosa de prefixos nas colunas finais (`QTD_`, `VAL_`, `PCT_`) e arredondamento global de variáveis monetárias para 2 casas decimais, otimizando o armazenamento em formato Parquet sem perda de precisão preditiva.

3. Dicionário de Variáveis e Regras de Construção

As *features* foram agrupadas em 4 domínios lógicos de comportamento:

A. Domínio: Recência e Frequência (Engajamento)

Avalia o ritmo e a lealdade do cliente com os serviços da operadora.

Variável	Descrição Regra Construção / de	Relevância para o Modelo (FPD)
QTD_DIAS_ULTIMA_RECARGA	Mínimo de dias entre a última recarga e a data da safra.	Clientes com recência alta (sumiram) têm menor propensão de pagar a fatura do novo plano.
QTD_RECARGAS_HIST	Contagem total de recargas feitas no histórico.	Mede a lealdade de longo prazo.
VAL_MEDIA_DIAS_ENTRE_RECARGAS	Razão entre a janela total de tempo e o número de recargas.	Indica o "ciclo de vida" financeiro (ex: cliente semanal vs. cliente mensal).
QTD_RECARGAS_U30D / U31_90D	Contagem de recargas na janela dos últimos 30 dias, e na janela de 31 a 90 dias.	Identifica mudanças recentes de comportamento (janelas móveis).

QTD_CELULARES_RECARREGADOS	Contagem distinta de DW_NUM_NTC recarregados pelo mesmo CPF.	Identifica o "Provedor de Família". Geralmente possui menor Churn, mas se inadimplir, o impacto é sistêmico.
----------------------------	--	--

B. Domínio: Valor Monetário (Capacidade de Pagamento)

Traduz o "tamanho do bolso" do cliente.

Variável	Descrição / Regra de Construção	Relevância para o Modelo (FPD)
VAL_TOTAL_CREDITO_HIST	Soma bruta de todo o crédito inserido.	Define o valor do cliente para a empresa (LTV histórico).
VAL_MAX_RECARGA	O maior valor de recarga única já feito pelo cliente.	Estabelece o "teto" de liquidez imediata do cliente.
VAL_MEDIA_RECARGA	Ticket médio das recargas brutas.	Se o ticket médio for R\$ 15 e o plano Controle for R\$ 50, o risco de choque financeiro é alto.

VAL_TOTAL_REAL_HIST	Soma do crédito deduzindo o valor do SOS tomado e a respectiva taxa administrativa.	O verdadeiro dinheiro novo que entrou no caixa da empresa.
PCT_MOMENTUM_RECARGA_30D	Razão entre o valor recarregado nos últimos 30 dias contra a média da janela anterior (31-90 dias).	Feature de tração. Se < 1, o cliente está reduzindo os gastos (Sinal de alerta para default).

C. Domínio: Risco e Socorro Financeiro (SOS)

O termômetro direto de estresse financeiro. *A regra da taxa foi reconstruída dinamicamente baseada nas faixas (R\$3 -> tx R\$1.0; R\$5 -> tx R\$2.0; R\$10 -> tx R\$3.5, etc).*

Variável	Descrição / Regra de Construção	Relevância para o Modelo (FPD)
QTD_USO_SOS_HIST	Número de vezes que a FLAG_SOS foi acionada.	Clientes que usam SOS repetidamente vivem no limite do orçamento.
VAL_MEDIA_SOS_TOMADO	Média do valor de socorro (calculado apenas sobre os eventos onde houve SOS).	Indica a gravidade do "furo" no orçamento do cliente.

VAL_TOTAL_TAXA_SOS_PAGA	O custo administrativo total pago pelo cliente por antecipar saldo.	Mostra o quanto o cliente aceita pagar de "juros" por liquidez imediata.
PCT_DEPENDENCIA_SOS	Razão: VAL_TOTAL_SOS_TOMADO / VAL_TOTAL_CREDITO_HIST.	Feature Ouro de Risco. Clientes onde o SOS representa > 20% do volume transacionado têm probabilidade crítica de FPD.

D. Domínio: Perfil e Hábitos (Dummies / Frequência Categórica)

Em vez de simples variáveis binárias (1/0), foi aplicado o método de pivoteamento frequencial. Se a variável é QTD_TURN0_MADRUGADA, ela conta *quantas* vezes o cliente recarregou na madrugada.

Variável	Descrição / Regra de Construção	Relevância para o Modelo (FPD)
QTD_TURN0_{PERIODO}	Agrupamento do horário exato da recarga em 4 turnos (Madrugada, Manhã, Tarde, Noite).	Separa perfis de rotina. Recargas de madrugada podem correlacionar com trabalhadores noturnos ou impulsividade.

QTD_CANAL_{AGRUPAMENTO}	Classificação via Regex do canal de aquisição (Bancos Tradicionais, Fintechs, Varejo Físico, Gateways).	O meio de pagamento revela bancarização. Clientes de Fintechs têm perfil de crédito diferente dos que pagam em dinheiro na lotérica.
QTD_PLANO_{AGRUPAMENTO}	Classificação via Regex da fragmentação de planos (Pré Core, Controle Híbrido, Legado, Regionalizado).	Diferencia o cliente que usa o produto foco de clientes que retiveram planos antigos obsoletos.

4. Relevância Estratégica para o Projeto

A construção deste Book transforma dados transacionais brutos em **Sinais de Alerta Precoce**.

No contexto do desafio de Telecom (migração para o plano Controle), o modelo tradicional de Credit Scoring bancário pode conter lacunas de informações. Ao criar features como a **Razão de Dependência do SOS** e a **Análise de Momentum 30D**, o algoritmo passa a enxergar a "fome de saldo" e a capacidade real de pagamento contínuo do usuário.

A limpeza da cauda longa por *Regex* e a arquitetura sem *Data Leakage* asseguram que o modelo treinado terá capacidade de generalização na vida real (produção), colocando esta solução em um patamar de maturidade analítica.