

# Relatório: Modelo de Machine Learning (Projeto Claro Controle)

## 1. Visão Geral do Projeto

Desenvolvimento de um motor de decisão baseado em Inteligência Artificial para otimizar a migração de clientes Pré-pagos para planos Controle, visando expansão de base com mitigação de risco de inadimplência.

## 2. Infraestrutura e Engenharia de Dados

A arquitetura do projeto foi desenhada para equilibrar processamento massivo e agilidade de entrega:

- **Ambiente de Desenvolvimento:** Utilização do **OCI Data Science (Oracle Cloud Infrastructure)**.
- **Especificação de Hardware:** Instância **VM.Standard.E5.Flex** configurada com **5 OCPUs** e **60 GB de Memória RAM**. Essa escolha permitiu o processamento paralelo eficiente do XGBoost e a manipulação de grandes volumes de dados em memória a um custo estimado de ~ \$0,27 / hora.
- **Estratégia de Amostragem:** Foi aplicada uma **amostragem de 35% dos dados totais**. Esta decisão estratégica garantiu representatividade estatística para o modelo, mantendo a agilidade necessária para o ciclo de desenvolvimento do Hackathon.
- **Qualidade de Dados:** Garantia de uma base *null-free* via pipeline de engenharia, eliminando ruídos de imputação e assegurando a integridade das variáveis comportamentais.

## 3. Estruturação do Modelo

O algoritmo selecionado foi o **XGBoost (Extreme Gradient Boosting)**.

### Justificativa da Escolha:

- **Eficiência Computacional:** Otimizado para rodar em arquiteturas como a E5.Flex da Oracle, utilizando múltiplos núcleos (OCPUs) simultaneamente.
- **Poder Discriminante:** Superioridade no ranqueamento de risco em comparação aos Scores tradicionais de mercado.
- **Hiperparâmetros Finais (Tuning via GridSearch):**
  - **learning\_rate: 0.05** (Aprendizado conservador para maior estabilidade).
  - **max\_depth: 7** (Captura de interações profundas entre variáveis).
  - **n\_estimators: 300** (Robustez através de um grande comitê de árvores).
  - **subsample: 0.8** (Prevenção de overfitting através de amostragem aleatória de linhas).

## 4. Avaliação de Performance e Estabilidade

O modelo foi submetido a teste de estresse temporal:

### Análise por Safra (Vintages):

- **Performance em Treino:** \$KS\$ de aproximadamente **40%** e Gini de **53%**.
- **Performance OOT (Out-of-Time):** Conforme esperado em cenários reais, houve uma variação na transição para dados inéditos, mantendo um **KS resiliente na casa dos 34%**.
- **Conclusão Técnica:** A manutenção de um  $KS > 30\%$  e acima do benchmark proposto  $KS > 33,1\%$  em safras futuras (OOT) confirma a robustez do modelo e sua capacidade de generalização para a operação da Claro.

## 5. Simulação de Impacto de Negócio

O valor gerado foi validado cruzando a inteligência do modelo com as metas comerciais:

- **Atual:** Aprovação de 73% com Inadimplência (FPD) de 23%.
- **Novo Cenário (IA):** Expansão da aprovação para **77%** da base (aumento de 4% em vendas).
- **Resultado:** O modelo permite capturar esses novos clientes mantendo a inadimplência dentro dos limites aceitáveis pela companhia, otimizando o *Life Time Value* (LTV) do cliente migrado.

## 6. Entrega

Este projeto culmina na entrega de um **protótipo funcional e escalável**, submetido para avaliação técnica e análise de viabilidade de implementação. Estão incluídos os seguintes artefatos:

- **Artefatos de Engenharia:** Arquivos de modelo (`modelo_final_xgboost.pkl`) e bases de treino e teste.
- **Script :** O arquivo `codigo_escoragem_Squad_6.ipynb`, está estruturado para validação do modelo e apuração das métricas.
- **Abertura para Colaboração:** O time coloca-se à inteira disposição da banca examinadora e das áreas técnicas da Claro para detalhamentos adicionais, ajustes de parâmetros conforme novas regras de negócio ou simulações complementares que validem a segurança desta transição.

## 7. Monitoramento e Governança

Para garantir que o modelo mantenha a precisão ao longo do tempo, propomos uma estrutura de monitoramento contínuo baseada em dois pilares:

### A. Estabilidade da População (Data Drift)

- **PSI (Population Stability Index):** Monitoramento mensal para detectar se o perfil dos novos clientes que estão entrando na Claro mudou drasticamente em relação à base de treinamento de 35%.
- **CSI (Characteristic Stability Index):** Avaliação individual das 80 variáveis para identificar se alguma *feature* específica (ex: Momentum de Recarga) perdeu o poder preditivo devido a mudanças no mercado.

## **B. Performance de Crédito (Concept Drift)**

- **Acompanhamento de Safra (Vintages):** Monitoramento do *KS* e *Gini* mensal. Caso o *KS* caia abaixo de um limiar crítico (ex: <28 %), um gatilho de **Retreinamento** deve ser acionado.
- **Backtesting Real:** Comparação contínua entre o calote previsto pela IA e o calote real observado após 30/60 dias (FPD).